Livrable 2 — Choix des méthodes d'évaluation

Analyse automatique de partitions musicales (OMR)

Thibault Bourdoiseau & Léo Li

13 juin 2026

1. Contexte

Le système à évaluer est une chaîne de reconnaissance optique de partitions (OMR) qui transforme l'image d'une partition imprimée ou manuscrite en une liste de notes (hauteur et durée), exportable au format MIDI [1, 2]. On évalue à **trois critères numériques complémentaires**, chacun ciblant une étape de la chaîne : la *précision des hauteurs* et la *précision des durées* mesurent le décodage musical (le résultat final), tandis que le *F1 de détection* mesure en amont la localisation des symboles. Chaque critère compare une **prédiction** produite par le programme à une **vérité-terrain**.

2. Critère 1 — Précision des hauteurs (Pitch Accuracy)

Comment se calcule-t-il (critère numérique). On apparie d'abord la séquence de notes prédite à la séquence de référence par **distance d'édition** (Levenshtein [3]), puis sur les N notes de référence :

$$\mathrm{PA} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\Big[\hat{h}_i = h_i\Big] \times 100,$$

où h_i est la hauteur de référence (p. ex. `C4`) et $\hat{h}_i$ la hauteur prédite alignée (une note non appariée compte comme fausse). Une note est correcte si *nom et octave* coïncident. L'alignement par édition (plutôt que position par position) évite qu'une seule note manquée décale toutes les suivantes et effondre artificiellement le score. **Ce qu'il caractérise.** La qualité du *décodage vertical* : lecture de la position de la tête de note sur la portée, prise en compte de la clef et des altérations. C'est le critère le plus directement lié à l'utilisabilité de l'export MIDI. **Valeur raisonnable.** PA $> 90\,\%$ excellent (usage réel), 75–90 % correct (prototype fonctionnel), $< 75\,\%$ insuffisant (décodage à revoir). Valeurs dans $[0, 100]\,\%$.

3. Critère 2 — Précision des durées (Rhythm Accuracy) et Note Accuracy

Comment se calcule-t-il. Sur le même alignement que le critère 1 :

$$\mathrm{RA} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\Big[\hat{d}_i = d_i\Big] \times 100, \qquad \mathrm{NA} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\Big[\hat{h}_i = h_i\Big]\,\mathbf{1}\Big[\hat{d}_i = d_i\Big] \times 100,$$

où $d_i \in \{\text{ronde, blanche, noire, croche, double croche, } \ldots\}$. La **Note Accuracy** exige hauteur *et* durée correctes simultanément ; on a toujours $\mathrm{NA} \le \min(\mathrm{PA}, \mathrm{RA})$, ce qui en fait un résumé sévère mais fidèle du résultat exploitable. **Ce qu'il caractérise.** La *classification des symboles de durée* : type de tête (pleine ou vide), présence d'une hampe, de ligatures et de points. La RA est souvent plus dure à atteindre que la PA car elle dépend de plusieurs étapes successives. **Valeur raisonnable.** Mêmes seuils que la PA ($> 90\,\%$ usage réel, $> 80\,\%$ prototype). Les erreurs de durée sont particulièrement pénalisantes pour le MIDI car elles décalent toutes les notes suivantes dans le temps. Valeurs dans $[0, 100]\,\%$.

4. Critère 3 — F1 de détection des têtes de notes

Comment se calcule-t-il. On compare les boîtes englobantes prédites aux boîtes de référence. Une détection est un vrai positif (TP) si son recouvrement IoU $\ge \tau$ avec une boîte de référence ($\tau = 0{,}5$, convention PASCAL VOC [4]) ; l'appariement est glouton (une référence ne sert qu'une fois). Les FP sont les détections sans correspondance, les FN les têtes non détectées :

$$\text{Précision} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FP}}, \qquad \text{Rappel} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}}, \qquad \mathrm{F1} = \frac{2 \cdot \text{Préc.} \cdot \text{Rappel}}{\text{Préc.} + \text{Rappel}}.$$

Ce qu'il caractérise. L'étape de *segmentation et de détection* des objets, indépendamment du décodage musical. Il sert de diagnostic : un F1 élevé avec une PA faible indique que les notes sont bien localisées mais mal interprétées (clef, position), tandis qu'un F1 faible pointe la détection. **Valeur raisonnable.** F1 $> 0{,}80$ attendu pour un prototype, $> 0{,}90$ pour un système robuste. On rapporte précision et rappel séparément, car ils orientent le réglage de la chaîne (seuils morphologiques, filtrage des composantes connexes). Valeurs dans $[0, 1]$.

5. Outils de calcul

Les trois critères sont implémentés dans `tools/metrics.py` (NumPy uniquement) : `detection_f1` (critère 3) renvoie précision/rappel/F1 à partir des boîtes ; `note_scores` (critères 1–2) renvoie PA, RA et NA à partir des deux séquences de notes (alignement par distance d'édition). Le script `tools/evaluate.py` lit une vérité-terrain et une prédiction et affiche les scores. La base d'évaluation est décrite dans le document séparé *Livrable 2 — Base d'évaluation.*

6. Références

[1] Jorge Calvo-Zaragoza, Jan Hajič Jr. et Alexander Pacha. "Understanding Optical Music Recognition". In : *ACM Computing Surveys* 53.4 (2020), p. 1-35.

[2] Ana Rebelo et al. "Optical music recognition : state-of-the-art and open issues". In : *International Journal of Multimedia Information Retrieval* 1.3 (2012), p. 173-190.

[3] Vladimir I. Levenshtein. "Binary codes capable of correcting deletions, insertions, and reversals". In : *Soviet Physics Doklady* 10.8 (1966), p. 707-710.

[4] Mark Everingham et al. "The PASCAL Visual Object Classes (VOC) Challenge". In : *International Journal of Computer Vision* 88.2 (2010), p. 303-338.